


Strategic Lakehouse


Une IA n'est réellement intelligente qu'à la hauteur des données fiables et structurées qu'on lui confie.



Maturation data-driven du SI à l'ère de l'IA

Introduction du sujet

La société (fictive) **GlobalTrade Solutions** souffre d'un système d'information fragmenté en silos : un ERP on-premise vieillissant, un CRM SaaS déconnecté, et des fichiers isolés sans **gouvernance** commune. Cette fragmentation



En tant que **consultants experts**, votre mission est de spécifier et prototyper une **architecture Lakehouse unifiée** capable de centraliser les données métier et d'exposer des indicateurs BI à la demande. Le périmètre est volontairement ciblé : pas de déploiement cloud réel, mais une **conception rigoureuse et un POC fonctionnel démontrable**.

Phase 1 – Diagnostic et choix d'architecture

Cartographiez le SI existant sur **deux niveaux** (fonctionnel et applicatif) pour identifier les silos et leurs impacts sur la chaîne de valeur analytique de



GlobalTrade Solutions. Considérer pour illustrer cette partie [ce dataset commercial fragmenté](#), constitué des silos suivants :

- Silo **ERP on-prem** (GlobalTrade ERP) : tables produits, stocks, ventes historiques (g_dim_products, g_fact_sales).
- Silo **CRM SaaS** (GlobalTrade CRM Cloud) : table clients + fichier CSV d'interactions ou campagnes CRM qu'on peut dériver à partir de g_dim_customers
- Silo **fichiers analytiques** (GlobalTrade Analytics) : extractions CSV/Parquet de ventes agrégées (views ou exports dérivés de g_fact_sales par jour / canal / pays).

Constatez le silotage des données, et proposez une [approche data-driven](#) pour une évolution du SI prête à l'arrivée de futures couches IA-agentiques dans la business-intelligence de l'entreprise. NB : vous n'avez pas besoin d'exploiter et d'étudier complètement le dataset, mais uniquement de vous en inspirer pour la conception de votre projet.

Après une veille sur la thématique de la gouvernance du SI et l'approche data-driven, rédigez une [analyse comparative](#) (tableau synthétique) des trois architectures cibles : Data Warehouse Cloud, Data Lake et Lakehouse. Critères : coût, scalabilité, latence, conformité RGPD, aptitude à l'IA.

Rédigez enfin une [recommandation d'une page](#) justifiant le choix du Lakehouse pour GlobalTrade, articulée autour de trois arguments stratégiques démontrables.

Phase 2 — Spécification technique



Définissez le **modèle de données en 3 couches Bronze / Silver / Gold** avec des exemples de tables pour au moins deux domaines métier (ex : ventes, stocks). Justifiez les choix de transformation entre chaque couche.

Rédigez un **cahier des charges fonctionnel** listant 5 à 8 fonctionnalités prioritaires (ingestion, stockage, requêtage, API BI, gestion des droits) avec pour chacune : description, critère d'acceptation et priorité **MoSCoW**.

Identifiez **5 risques clés** (RGPD, perte de données, indisponibilité, sécurité des accès, dette technique) avec une mesure de mitigation concrète pour chacun, présentée sous forme de matrice.

Ajoutez au cahier des charges une section "**Conformité et Accessibilité Numérique**":

- Citer les normes de référence (ex: **RGAA** – Référentiel Général d'Amélioration de l'Accessibilité ou **WCAG**).
- Lister **3 mesures concrètes** prévues pour le futur dashboard de l'entreprise (ex: gestion des contrastes pour les malvoyants, compatibilité avec les lecteurs d'écran pour les KPI, navigation clavier intégrale)

Phase 3 – Conception et POC

Produisez **3 schémas UML / C4** : diagramme de contexte système, diagramme de composants de l'architecture interne du Lakehouse, et diagramme de flux d'ingestion de la source brute à la couche Gold.

Implémentez un **POC minimal de bout en bout** démontrant le concept Lakehouse :



- **Couche Bronze** : ingestion d'un fichier CSV simulé (Python / Pandas ou DuckDB)
- **Couche Silver** : transformation simple (nettoyage, typage, dédoublonnage)
- **Couche Gold + API** : requête Gold exposant un KPI via Flask ou FastAPI (réponse JSON)
- *Bonus : interface web minimaliste (HTML/JS) affichant le KPI en temps réel*

L'intégration des **recommandations sur l'accessibilité** doit être démontrable, même sur un prototype minimaliste.

Exigence sur l'interface Web : L'interface (Flask/FastAPI + HTML) doit respecter des règles de base d'accessibilité. Respectez les contraintes techniques suivantes :

- Utilisation de balises HTML sémantiques (titres `<h1>`, labels de formulaires `<label>`).
- Vérification de la lisibilité des données (KPI) avec un score de contraste conforme aux normes PSH.

Tout le code source est **versionné sur Git** avec un README de lancement clair et reproductible.

Phase 4 — Présentation

Préparez une **présentation de 15 à 20 slides** simulant une restitution devant un COMEX fictif. La présentation doit retracer :

problématique → **analyse** → **choix** → **architecture** → **démonstration POC** → **recommandations**.



En tant que consultant, vous justifiez l'intérêt stratégique de l'inclusion.

- ajouter un point spécifique dans les "recommandations" montrant que **l'accessibilité du SI augmente l'adoption de l'outil** par l'ensemble des collaborateurs de GlobalTrade et réduit la dette technique de conformité.
- **Justification orale :** Être capable de répondre à une question sur l'impact de l'asynchronisme ou de la fragmentation des données sur l'accès à l'information pour un utilisateur en situation de handicap.

Compétences visées

Bloc 1 : Définir une stratégie de systèmes d'information

- **C4 : Schématiser une cartographie du SI** en utilisant une méthode d'analyse de risques pour anticiper les besoins du projet.
- **C5 : Élaborer la stratégie informatique** de l'entreprise à partir de la cartographie validée afin de proposer des axes d'évolution.
- **C7 : Comparer les différents types d'architectures** en identifiant leurs caractéristiques et leurs cas d'usage afin de schématiser clairement leurs interactions.
- **C8 : Analyser les composants de ces architectures** en indiquant leurs fonctions, interactions/dépendances afin d'évaluer leur performance et de proposer des améliorations.



- **C9 : Comprendre les avantages et inconvénients de chaque type d'architecture** en analysant leur performance, leur scalabilité et leur sécurité afin de **recommander les solutions architecturales les plus appropriées** pour répondre aux exigences spécifiques du projet et aux contraintes de sécurité et d'éco-conception.

Bloc 2 : Piloter des projets informatiques

- **C12 : Constituer des solutions techniques** en coordonnant les processus clés requis dans le cahier des charges fonctionnel afin de construire un **cahier des charges techniques** respectant les **RGPD** et intégrant des mesures spécifiques pour garantir l'**accessibilité aux personnes en situation de handicap (PSH)**.
- **C13 : Dans le cahier des charges technique, décrire chaque fonctionnalité attendue** en les priorisant selon une méthode de **modélisation des processus métier**, et en tenant compte des contraintes et de l'existant, afin de garantir que toutes les exigences sont correctement spécifiées.
- **C17 : Développer et intégrer des stratégies de mitigation des risques** en identifiant et évaluant les menaces potentielles afin de gérer la sécurité du projet.

Bloc 3 : Concevoir et développer une application informatique

- **C21 : Concevoir une architecture applicative** selon la complexité du système d'information existant en analysant les besoins fonctionnels et les exigences de sécurité, afin de produire des maquettes représentatives qui facilitent la validation et l'implémentation du projet.



- **C22 : Schématiser les processus métier** en tenant compte des contraintes, des éléments existants, et des vulnérabilités, et en les priorisant pour garantir une conception efficace et un développement optimal.
- **C23 : Recommander un environnement informatique**, en précisant les interactions entre les composants infrastructure et applicatifs et en intégrant les techniques permettant de **réduire l'impact écologique** à partir de critères comparatifs et argumentés.

Bloc 4B (Option) : Construire et implémenter des modèles de Big Data et d'IA

- **C31 : Concevoir une base de données** en analysant les exigences des traitements analytiques et d'IA, afin d'optimiser les performances et de faciliter l'extraction de connaissances et leur exploitation par des algorithmes

Rendu

Livrables attendus

Un dépôt GIT intitulé **Strategic Lakehouse**, contenant les documents et éléments suivants :

Synthèse diagnostic + recommandations

Spécification technique (CDC + matrice risques)



Code source POC + README

Présentation soutenance

Modalités de Soutenance

Format : 20 minutes de présentation + 10 minutes de questions jury.

Mise en scène : simulation d'une restitution devant un **CTO et un CDO fictifs** de GlobalTrade Solutions. Le groupe assume pleinement le rôle de cabinet de conseil.

Démonstration obligatoire : lancement en live du POC (appel API retournant un KPI) ou capture vidéo si instabilité technique. La démonstration doit être reproductible depuis le README du dépôt Git.

Base de connaissances

Maturité data et SI data-driven

- Comprendre le data maturity model : [datagalaxy](#)
- Data maturity model : étapes et bénéfices : [acceldata](#)

Data lake, data warehouse, lakehouse

- Data warehouse vs data lake vs data lakehouse : [striim](#)
- Lakehouse medallion Bronze / Silver / Gold (documentation Databricks)
: [learn.microsoft](#)



Urbanisation du SI et gouvernance

- Urbanisation du SI : principes, enjeux, méthode : [wandesk](#)
- Urbanisation du SI et trajectoire, avec exemples de MDM / ERP: [blueway](#)
- Urbanisation du SI à l'ère de l'IA : [eleven-labs](#)